

Báo cáo Tiến độ Tuần #2-3

Đánh giá Benchmark các Thuật toán Phân cụm Luồng trong River

Kỳ báo cáo	31/08/2026 – 13/09/2026	Ngày báo cáo	September 11, 2026
Giai đoạn	Giai đoạn 1 & 2 - Pipeline, Metrics & Tích hợp Thuật toán		

1. Tóm tắt Tổng quan

Mục tiêu - Cài đặt River và thiết lập môi trường thực nghiệm, chạy các kiểm thử xác thực, triển khai các thuật toán nền tảng, xây dựng khung làm việc tùy biến để benchmark và đánh giá các thuật toán phân cụm luồng. Khung làm việc kết hợp đầy đủ các metrics nội tại/ngoại vi cần thiết cho việc đánh giá toàn diện và xây dựng phương pháp luận benchmark siêu tham số khách quan.

Trạng thái - **IN PROGRESS** Tiến độ viết mã đi trước kế hoạch; công tác kiểm chứng (verify) đối chiếu với bài báo gốc đang được tiến hành

Bảng Theo dõi Tiến độ

Table 1: So sánh giữa kế hoạch đề xuất và tiến độ thực tế trong kỳ báo cáo này.

Giai đoạn / Tuần	Mục tiêu Đề xuất	Tiến độ Thực tế	Trạng thái	Mức hoàn thành
P1.2 (Tuần 2)	Nghiên cứu các thuật toán River	Đã cài đặt River, thiết lập môi trường, chạy các test kiểm chứng, tìm hiểu framework và pipeline	DONE	100%
P2.1 (Tuần 3)	Xây dựng framework benchmark	Đã tích hợp 9 metrics (ARI, NMI, AMI, Purity, RI, Silhouette, SSQ, DB, CH), đăng ký toàn bộ thuật toán; hiện chỉ gồm metrics tĩnh, chưa có metric đo khả năng thích ứng với drift	IN PROGRESS	—
Tuần 4	Bộ dữ liệu tổng hợp có trôi dạt khái niệm (drift)	Chưa bắt đầu; các luồng tổng hợp hiện có mới chỉ tái lập Ring-Ball và Smileface-Twomoons của SVStream	PLANNED	—
P3.1 (Tuần 6-7)	Cài đặt nhóm thuật toán đầu tiên (làm sớm)	Đã viết mã cho 10 thuật toán (5 nền tảng + 5 mở rộng); đã tái hiện một phần SVStream (Mục 3), 9 thuật toán còn lại chưa được đối chiếu kiểm chứng	IN PROGRESS	—
Kế hoạch Chiến lược	Thống nhất lộ trình	Ưu tiên kiểm chứng các thuật toán nền tảng trước	DONE	100%
Phương pháp luận	Thiết kế quy trình benchmark	Vận dụng ý tưởng LODO từ benchmark phát hiện trôi dạt dữ liệu [1]; đề xuất phương pháp LODO tham số tương đối (đóng góp của chúng tôi, chưa đánh giá thực nghiệm)	IN PROGRESS	—

Takeaway. Hạ tầng pipeline và các chỉ số đánh giá đã sẵn sàng, mã nguồn của cả 10 thuật toán đã được viết xong vượt trước kế hoạch ban đầu. Tuy nhiên, khâu kiểm chứng đối chiếu vẫn đang tiếp diễn: SVStream mới chỉ được tái lập một phần, trong khi các bộ dữ liệu drift và các chỉ số đo tính thích ứng thời gian thực chưa được bắt đầu.

Tổng thể: Tuần 2-3/18: tiến độ triển khai mã nguồn vượt kế hoạch; công tác kiểm chứng và các mối liên quan đến concept drift đang chờ thực hiện.

2. Các Công việc Đã Hoàn thành

C1. Thiết lập Pipeline River và Tích hợp Bộ Chỉ số Đánh giá (Giai đoạn 1 & 2)

- Đã cài đặt River và xây dựng một khung thực thi pipeline thống nhất nhằm tối ưu hóa việc vận hành mô hình luồng, đánh giá và tích hợp thuật toán.
- Đã triển khai và đóng gói đầy đủ các chỉ số đánh giá phân cụm tương thích trực tiếp với các luồng dữ liệu của River:
 - **Chỉ số ngoại vi (External metrics):** Adjusted Rand Index (ARI), Normalized Mutual Information (NMI), Adjusted Mutual Information (AMI), Purity, Rand Index (RI).
 - **Chỉ số nội tại (Internal metrics):** Hệ số Silhouette, Tổng bình phương sai số (SSQ/SSE), Chỉ số Davies–Bouldin (DB), Chỉ số Calinski–Harabasz (CH).

C2. Triển khai Thuật toán Phân cụm Luồng và Chiến lược Ưu tiên (Giai đoạn 3)

- Đã viết mã nguồn cho 10 thuật toán phân cụm luồng. Các thuật toán này hiện chưa được kiểm chứng đối chiếu toàn diện với bài báo gốc; SVStream là thuật toán đầu tiên đang trong quá trình kiểm chứng (Mục 3).
 - **Nhóm nền tảng, chuẩn mực và được trích dẫn rộng rãi:** DStream, HPStream, Birch [4], RepStream [6], SVstream [8]. Birch vốn là phương pháp duyệt một lượt (one-pass) cho tập dữ liệu tĩnh kích thước lớn thay vì thuật toán phân cụm luồng tuần tự; thuật toán này được giữ lại làm baseline về cây CF mà các phương pháp luồng (như CluStream) kế thừa và phát triển.
 - **Mô hình khám phá/khác:** DDStream, MrStream, DCUstream, improved_Birch [5], SOSstream [7].
- **Chiến lược Triển khai:** Ưu tiên các thuật toán nền tảng vì chúng được trích dẫn nhiều, đặc tả thuật toán rõ ràng và có các thí nghiệm bài bản để đối chiếu mã nguồn. Mục 3 chỉ ra rằng ngay cả với nhóm này, việc tái lập chính xác 100% cũng gặp nhiều hạn chế (dữ liệu không được công bố, đồ thị thiếu trục tọa độ, tham số mô tả mơ hồ); do đó, mỗi bản cài đặt cần được kiểm chứng đối chiếu kỹ lưỡng theo từng hình ảnh thí nghiệm trước khi được tính là hoàn tất.

C3. Nghiên cứu về Phương pháp luận Benchmark Siêu tham số cho Phân cụm Luồng (Phương pháp luận)

- **Thực trạng & Thách thức:**
 - **Vấn đề Quá khớp (Overfitting):** Hầu hết các tài liệu khoa học công bố các siêu tham số được tinh chỉnh thủ công riêng trên các tập dữ liệu do chính tác giả lựa chọn. Khi chạy benchmark trên các tập dữ liệu khác, hiệu năng suy giảm nghiêm trọng hoặc xuất hiện hiện tượng tăng vọt đột biến về thời gian chạy/bộ nhớ RAM. Trong học máy tổng quát, tối ưu hóa siêu tham số (HPO) đóng vai trò then chốt để xác định cấu hình hoạt động tối ưu và bền bỉ [2].

- *So sánh Thiếu công bằng*: Việc lựa chọn tham số theo cảm tính (heuristic) hoặc tính chỉnh trên chính tập dữ liệu kiểm thử tạo ra độ chệch đánh giá (evaluation bias), như đã được chỉ ra đối với các bộ phát hiện trôi dạt khái niệm trong [1]; chúng tôi nhận thấy điều tương tự cũng tồn tại trong phân cụm.
- *Mục tiêu Cốt lõi*: Xác định cấu hình siêu tham số có khả năng hoạt động ổn định và khách quan trên nhiều tập dữ liệu đa dạng, thay vì tìm kiếm bộ tham số chỉ tối ưu cục bộ trên một tập dữ liệu đơn lẻ.
- **Ý tưởng Tham khảo - Leave-One-Dataset-Out (LODO)**: được đề xuất trong [1] dành cho benchmark các phương pháp phát hiện trôi dạt khái niệm, vốn chưa phải là quy trình chuẩn tắc cho bài toán phân cụm; chúng tôi đã vận dụng và điều chỉnh phương pháp này.
 - *Cơ chế*: Sử dụng $n - 1$ tập dữ liệu để tìm kiếm cấu hình tối ưu (thông qua tìm kiếm ngẫu nhiên - random search) và đánh giá trên tập dữ liệu giữ lại còn lại. Giúp quá trình tinh chỉnh hoàn toàn độc lập với dữ liệu kiểm thử.
 - *Ưu điểm*: Không phụ thuộc vào mô hình (model-agnostic), khảo sát được không gian tham số rộng, trực quan, đảm bảo tính tái lập.
 - *Nhược điểm*: Chi phí tính toán rất lớn, không gian tìm kiếm khổng lồ, phụ thuộc nhiều vào yếu tố may rủi hơn là tri thức miền chuyên sâu.
 - *Hạn chế đối với Phân cụm (quan sát của chúng tôi, không trích xuất từ tài liệu đã xuất bản)*: LODO tiêu chuẩn gặp thất bại vì các tham số tinh tuyệt đối (ví dụ: ϵ cố định) không mang ý nghĩa hình học nhất quán giữa các tập dữ liệu có số chiều, thang đo và số lượng cụm khác biệt lớn (ví dụ: KDD99 có 23 cụm so với Shuttle chỉ có 2 cụm). Không thể tồn tại một giá trị tinh tuyệt đối nào phù hợp cho mọi trường hợp.
- **Đề xuất của Chúng tôi - LODO có Chủ đích với Tham số Tương đối** (chưa đánh giá thực nghiệm):
 - (a) **Chỉ Tinh chỉnh Tham số Trọng yếu**: Tập trung duy nhất vào 1–2 tham số then chốt (hoặc nhiều hơn tùy thuật toán) ảnh hưởng trực tiếp đến cấu trúc cụm và độ phân giải:
 - *Dựa trên tâm (KMeans, v.v.)*: k (số lượng cụm).
 - *Dựa trên mật độ (DenStream, v.v.)*: ϵ , `clustering_threshold` (bán kính micro-cluster và tiêu chuẩn gộp/tách).
 - *Dựa trên lưới (DStream, v.v.)*: `grid_width` (ngưỡng mật độ ô lưới).
 - *Phân cấp (BIRCH, v.v.)*: `threshold` (ngưỡng phân nhánh cây CF).
 - *Dựa trên đồ thị (RepStream, v.v.)*: α (mật độ điểm đại diện).
 - (b) **Sử dụng Tham số Tương đối qua Đặc trưng Thống kê Dữ liệu (param = $f(\text{stats})$)**: Tinh chỉnh các hệ số co giãn tương đối thay vì các giá trị tuyệt đối tĩnh:
 - $\epsilon = c \cdot d$, với d là khoảng cách trung vị từng cặp hoặc khoảng cách k -NN trung bình.
 - $\text{grid_width} = \text{range}(X)/g$, với g là số lượng phân đoạn mong muốn trên mỗi chiều.
 - $\text{threshold} = c \cdot \sigma$, với σ là độ lệch chuẩn trung bình trên các chiều thuộc tính.
 - k và α gắn liền với số lượng lớp hoặc ước lượng mode phân bố trong mẫu.
 - (c) **Lợi ích Cốt lõi**: Một hệ số co giãn duy nhất c sẽ tự động thích ứng với mật độ dữ liệu (tạo ϵ lớn hơn cho dữ liệu thưa, nhỏ hơn cho dữ liệu dày), loại bỏ hoàn toàn nhược điểm của việc áp đặt các giá trị tuyệt đối cứng nhắc trên các tập dữ liệu không đồng nhất. Ý tưởng này chia sẻ tinh thần tương đồng với việc tinh chỉnh siêu tham số theo hướng dữ liệu trong phân cụm [3], nhưng bản thân phương pháp LODO với tham số tương đối là đề xuất riêng của chúng tôi và hiện chưa được đánh giá thực nghiệm.

3. Tái hiện Thực nghiệm SVStream

Chúng tôi đã tái hiện (reproduce) nghiên cứu thực nghiệm của SVStream [8] (Hình 3–18) dựa trên phiên bản cài đặt trong River cùng khung benchmark tự xây dựng. Bất kỳ sai khác nào về dữ liệu đầu vào đều phản ánh trực tiếp lên kết quả, do đó phần này trước hết nêu rõ những thiết lập đầu vào nào có thể tuân theo bài báo gốc và những điểm nào không thể, kể đến trình bày cách xử lý và hiệu chuẩn các thông số còn bỏ ngỏ, và cuối cùng so sánh chi tiết kết quả theo từng hình.

3.1 Dữ liệu và Thiết lập Đầu vào: Những Điểm Tuân theo và Khác biệt so với Bài báo

- **Ring-Ball và Smileface-Twomoons không thể khớp hoàn toàn với bài báo** (Hình 3 và mọi hình sử dụng hai tập dữ liệu này). Bộ dữ liệu gốc không được công bố công khai và các hình ảnh trong bài báo không có trục tọa độ, nên việc phỏng đoán tọa độ bằng mắt sẽ không giúp dữ liệu tiệm cận bài báo hơn mà chỉ làm tăng tính tùy biến cảm tính. Chúng tôi giữ nguyên các đặc tính bài báo đã mô tả (kích thước mẫu, số lớp, tỷ lệ nhiễu, thứ tự các pha trôi dạt dữ liệu) và hiệu chuẩn thang đo tọa độ *một lần duy nhất* dựa theo giá trị q tối ưu trong Hình 15 của bài báo (Mục 3.2). Để khớp hoàn toàn cần phải có dữ liệu gốc từ nhóm tác giả.
- **Phương pháp chuẩn hóa các luồng dữ liệu thực tế không được nêu trong bài báo.** Phương pháp này cũng được lựa chọn thông qua cùng một bước hiệu chuẩn duy nhất và được ghi nhận tường minh.
- **KDD CUP'99 và Forest CoverType được lấy mẫu tiền tố.** Lần chạy này sử dụng 10.000 bản ghi đầu tiên của mỗi luồng trong tất cả các hình (Hình 14–16 và 18), trong khi bài báo chạy toàn bộ luồng với 494.020 và 581.012 bản ghi. Khung benchmark hỗ trợ chạy toàn bộ luồng, nhưng sẽ tiêu tốn hàng chục giờ tính toán. Hình 18 ngoài ra còn giữ nguyên thiết lập trước đó (online running z-score, $q = 0.02 / 0.15$, luồng tổng hợp không co giãn). Do đó, các chỉ số trên luồng dữ liệu thực không thể so sánh trực tiếp theo giá trị tuyệt đối với bài báo.

3.2 Hiệu chuẩn các Yếu tố Đầu vào Chưa Xác định

Thang đo tọa độ. Một hàm nhân Gaussian (Gaussian kernel) với độ rộng q trên dữ liệu được co giãn theo tỷ lệ s hoạt động tương đương với qs^2 trên dữ liệu chưa co giãn, do đó một lượt quét duy nhất giá trị q trên luồng chưa co giãn sẽ xác định được $s = \sqrt{q^*/q_{\text{paper}}}$. Ring-Ball đạt đỉnh tại $q^* = 8$ so với giá trị 9 trong bài báo ($s = 0.943$); Smileface-Twomoons đạt đỉnh tại $q^* = 50$ so với 11 ($s = 2.13$). Do thang đo được chọn bằng cách tối đa hóa chỉ số Rand trung bình tại các tham số mặc định của bài báo, nên các đồ thị luồng tổng hợp ở Hình 15 và chỉ số Rand trung bình ở Hình 5–6 và 11–12 không được coi là bằng chứng độc lập.

Chuẩn hóa dữ liệu. Tại giá trị q của bài báo, chúng tôi tính toán $q \cdot \max \|\mathbf{x}_i - \mathbf{x}_j\|^2$ trên khối (chunk) đầu tiên cho từng phương án chuẩn hóa ứng viên, vì Mục 4.4.2 của bài báo yêu cầu q phải lớn hơn nhẹ so với $1/\max \|\mathbf{x}_i - \mathbf{x}_j\|^2$, và loại bỏ những phương án chuẩn hóa khiến hầu như mọi giá trị nhân đều bằng 0 hoặc 1. Trên KDD CUP'99, chỉ có phương pháp online z-score đưa tích này về gần 1 (0.99). Trên CoverType, chỉ có min-max giữ lại được giá trị hàm nhân sử dụng được (với các phương pháp khác, hơn 99% giá trị hàm nhân xấp xỉ 0), nhưng tích của nó lên tới 27.6, do đó hàm nhân vẫn còn quá hẹp: đây là lựa chọn ít tệ nhất thay vì một phương án thực sự thỏa mãn tiêu chí (Mục 4, B4). Việc lựa chọn này hoàn toàn chỉ dựa trên thống kê hàm nhân, không sử dụng chỉ số Rand.

Table 2: Các yếu tố đầu vào của bản tái hiện so với bài báo gốc.

Yếu tố đầu vào	Bài báo gốc	Bản chạy này	Trùng khớp?
Tham số và lưới quét	Bảng 1 (M, q, C); $\delta = 0.6$, $\eta = 1$, $\zeta = 2$; lưới quét ở Hình 13-17	Giữ nguyên như bài báo ở Hình 3-17	Có
Luồng dữ liệu tổng hợp	Không công bố; hình không có trục tọa độ	Giữ nguyên các đặc tính mô tả; hiệu chuẩn thang tọa độ một lần duy nhất	Không
KDD CUP'99	494.020 bản ghi, 34 thuộc tính, “loại bỏ 1 điểm ngoại lai”	10.000 bản ghi đầu theo thứ tự gốc (bài báo không nêu rõ đã loại bỏ điểm ngoại lai nào; theo phỏng đoán của chúng tôi, bản ghi có chuẩn z-score lớn nhất tại vị trí 346.366 nằm ngoài đoạn này)	Không
Forest CoverType	581.012 bản ghi, 10 thuộc tính	10.000 bản ghi đầu theo thứ tự gốc	Không
Chuẩn hóa dữ liệu	Không đề cập	Hiệu chuẩn một lần: KDD dùng online z-score, CoverType dùng min-max	Không
Lưới quét Hình 13	$C \in [0.26, 0.34]$	13a: lưới của bài báo; 13b: $C \in [0.010, 0.022]$, vùng ràng buộc hộp phát huy tác dụng	Chỉ khớp 13a
Hình 18	Toàn bộ luồng, q gốc của bài báo	10.000 bản ghi, online z-score, $q = 0.02 / 0.15$, luồng tổng hợp không co giãn	Không
Mô hình đối chuẩn, nền tảng	Có StrAP; cài đặt không nêu rõ trên PC Core2 Duo; đo bộ nhớ đỉnh (peak memory)	Baseline trong River không có StrAP; Python; kích thước mô hình (model size)	Không






Figure 1: Hiệu chuẩn. (a, b) Chỉ số Rand khi quét q trên các luồng tổng hợp chưa co giãn: đường đứt nét là q tốt nhất; đường chấm là q của bài báo dưới thang đo đã chọn. (c) Tỷ lệ các cặp điểm lấy mẫu có giá trị hàm nhân mang thông tin tại giá trị q của bài báo ứng với từng phương án chuẩn hóa; các con số thể hiện $q \cdot \max \|\mathbf{x}_i - \mathbf{x}_j\|^2$ trên chunk đầu tiên, cột có viền đậm là phương án chuẩn hóa được chọn.

3.3 Kết quả Thực nghiệm và Phân tích Chi tiết

Toàn bộ các hình bên dưới được tạo ra từ các thiết lập đầu vào trong Bảng 2. Mỗi hình đều đi kèm phần phân tích chi tiết về sự tương đồng và khác biệt so với bài báo gốc.

Table 3: Kết quả bài báo gốc vs. lần chạy thực nghiệm này. [†]Giá trị được dùng để hiệu chuẩn thang đo tọa độ.

Hình	Bài báo gốc	Lần chạy này	Khớp?
3	Hai luồng tổng hợp	Tái tạo lại, co giãn theo tỷ lệ 0.943 và 2.13	Đầu vào
4	$C = 0.25$: 76 SV, 10 BSV, tách biệt các lớp; $C = 1$: gộp thành 1 cụm	$C = 0.25$: 173 SV, 0 BSV , 8 cụm (RI chung 0.951); $C = 1$: 1 cụm (0.495)	Một phần
5–6	RI trung bình 0.9267; RI thấp chỉ ở chunk 1–2	RI trung bình 0.9192[†] ; RI dưới 0.9 ở chunk 1–6	Có
7–10	53–126 SV+BSV, 3–14 BSV	138→506 SV, 0 BSV; RI chung 0.96–1.00, hai mất hội tụ bị gộp ở bước 70	Một phần
11–12	RI trung bình 0.9857; 65/70 chunk > 0.95	RI trung bình 0.9844[†] ; 63/70 chunk > 0.95	Có
13	Phát hiện 82–99%, báo động giả $< 6\%$; cả hai đều tăng khi ζ và C giảm và khi q tăng	13a: 0% ở mọi cấu hình. 13b: xu hướng ζ và C khớp, xu hướng q bị đảo ngược; tỷ lệ phát hiện phần lớn chỉ đạt 8–34%	Không
14	RI ổn định theo M ngoại trừ trên Ring-Ball; thời gian tăng theo M ; < 200 SV+BSV; 12–230 KB	RI ổn định; thời gian <i>giảm</i> khi M tăng; 110–874 SV+BSV; 18–181 KB	Một phần
15	q tốt nhất là 9 (Ring-Ball), 11 (Smileface); KDD ≈ 0.66 , CoverType ≈ 0.71	q tốt nhất là 11 (0.923) và 12 (0.986) [†] ; KDD 0.97–1.00; CoverType đi ngang ở 0.33	Một phần
16	Tồn tại cực trị rõ rệt theo C trên các luồng tổng hợp; CoverType tốt nhất tại $C = 0.2$	Đi ngang, hoặc dao động ngẫu nhiên không rõ xu hướng trên Ring-Ball	Không
17	Ổn định với $\delta \in [0.5, 0.6]$ và $\eta \in [0.9, 1.0]$, giảm khi δ và η nhỏ; chọn (0.6, 1.0)	Mặc định bằng hoặc cách giá trị tốt nhất trong vòng 0.002 (Ring-Ball 0.919; Smileface 0.984 so với 0.986); η không có tác động, không có hiện tượng sụt giảm khi δ và η nhỏ	Một phần
18	SVStream tốt nhất trên mọi luồng, bộ nhớ nhỏ nhất	Tốt nhất trên Ring-Ball và KDD; xếp sau các baseline trên Smileface chưa co giãn và CoverType	Một phần



Fig. 4. Comparing the performances of SVStream on Ring-Ball with ($C = 0.25$) and without ($C = 1$) BSVs.

(a) Bài báo gốc

(b) Lần chạy này

Figure 2: Hình 4, Ring-Ball tại bước 11 với $C = 0.25$ và $C = 1$ (lần chạy này bổ sung thêm cấu hình $q = 1$, $C = 0.04$).

Phân tích. Chỉ có hiện tượng sụp đổ tại $C = 1$ là tái hiện được: hai lớp bị hợp nhất thành một cụm duy nhất tương tự bài báo. Tại giá trị $C = 0.25$ của bài báo, chúng tôi hoàn toàn không thu được BSV nào (173 SV, 8 cụm), mặc dù chunk dữ liệu vẫn được phân cụm tốt (RI 0.951). Nguyên nhân xuất phát từ ràng buộc hộp trong Công thức (5): với $\sum_i \beta_i = 1$ và $\beta_i \leq C$, một hình cầu chỉ có thể chứa tối đa $\lfloor 1/C \rfloor$ BSV, tức là 4 BSV tại $C = 0.25$, trong khi bài báo lại hiển thị 10 BSV ở đây và 14 BSV tại $C = 0.3$ (Hình 8). Do đó, tham số C của tác giả nhiều khả năng đã được co giãn theo một thang khác. Khi cài đặt nguyên bản theo công thức toán học, ràng buộc hộp chỉ thực sự phát huy tác dụng khi C được hạ thấp, ví dụ xuống 0.04 (thu được 12 BSV).



(a) Bài báo gốc

(b) Lần chạy này

Figure 3: Hình 5–6, Chỉ số Rand theo từng chunk trên Ring-Ball và các chunk có kết quả kém nhất.

Phân tích. Chỉ số Rand trung bình rất sát với bài báo gốc (0.919 so với 0.927), tuy nhiên đây chính là giá trị mà thang đo tọa độ đã được hiệu chuẩn dựa vào. Các chunk ban đầu đều cho kết quả thấp ở cả hai bên, điều mà bài báo giải thích là do các chunk đầu tiên thừa thớt tạo ra khoảng trống giả bên trong các cụm; phía chúng tôi chỉ số duy trì dưới 0.9 trong suốt sáu chunk thay vì hai chunk. Hai hình biểu diễn chunk được tô màu theo mô hình ở cuối luồng thay vì tại bước của chính nó, đó là lý do vì sao chúng trông có vẻ chuẩn xác mặc dù các chunk này chỉ đạt điểm 0.71 và 0.70.




Fig. 7. SVStream on Smileface-Two moons: step 10.




Fig. 8. SVStream on Smileface-Two moons: step 12.




Fig. 9. SVStream on Smileface-Two moons: step 51.






Fig. 10. SVStream on Smileface-Two moons: step 70.

(a) Bài báo gốc

(b) Lần chạy này

Figure 4: Hình 7–10, Smileface-Two moons tại các bước 10, 12, 51 và 70: toàn bộ luồng đến thời điểm hiện tại, các hình cầu, và kết quả phân cụm của chunk.

Phân tích. Chỉ số Rand của chunk duy trì ở mức cao qua mọi bước (0.96–1.00), nhưng các cụm phân chia không hoàn toàn rõ ràng và gọn gàng như bài báo: tại bước 12, hai hình mặt trăng mới xuất hiện vẫn bị phân tách thành nhiều cụm nhỏ (0.956), và tại bước 70, hai mắt đang hội tụ lại bị gộp chung thành một cụm (0.971). Sự khác biệt nằm ở tập tóm tắt dữ liệu (summary). Vì không có BSV nào được sinh ra ở mức C của bài báo (xem Hình 4), cơ chế suy giảm BSV (BSV decay) không bao giờ loại bỏ được nhiều: các điểm nhiễu tồn tại vĩnh viễn dưới dạng SV cô lập và tập tóm tắt tăng vọt từ 138 lên 506 SV, trong khi bài báo giữ được ở mức 53 đến 126 SV+BSV và loại bỏ nhiễu dưới dạng các BSV (Hình 10a).



(a) Bài báo gốc

(b) Lần chạy này

Figure 5: Hình 11–12, Chỉ số Rand theo từng chunk trên Smileface-Twomoons và 5 chunk có kết quả kém nhất.

Phân tích. Hình này hiện đã khớp rất sát với bài báo: RI trung bình đạt 0.984 so với 0.986 và có 63 so với 65 chunk đạt trên 0.95. Các chunk yếu nhất là chunk 1 (0.87), chunk 7 (0.92) và các chunk 65–68 (hạ xuống 0.91), thời điểm hai mắt hội tụ vào nhau. Điểm trung bình là mục tiêu hiệu chuẩn nên không phải bằng chứng độc lập, nhưng chỉ số Rand vẫn duy trì ổn định ở mức 0.98 trên mọi giá trị M (Hình 14) và mọi giá trị C (Hình 16), những tham số không hề được can thiệp trong quá trình hiệu chuẩn, trong khi thuật toán chạy trên luồng chưa co giãn chỉ đạt 0.762 (Hình 18). Do đó, sự chênh lệch trước đây trên luồng này chủ yếu bắt nguồn từ thang đo dữ liệu, tức là hàm nhân quá rộng so với tọa độ không gian mẫu.




Fig. 13. The detection rate and false detection rate of outliers on Smileface-Twomoons with different C , C' , and q .

(a) Bài báo gốc

(b) 13a: Lưới của bài báo

(c) 13b: C vùng ràng buộc hợp phát huy tác dụng

Figure 6: Hình 13, Tỷ lệ phát hiện điểm ngoại lai so với tỷ lệ báo động giả trên Smileface-Twomoons khi thay đổi ζ , C và q .

Phân tích. Trên lưới tham số của bài báo (13a), không có BSV nào xuất hiện, do đó không có điểm nào bị gán nhãn ngoại lai và mọi tỷ lệ đều bằng 0%. Khi hạ C xuống vùng mà ràng buộc hợp phát huy tác dụng (13b), việc giảm ζ và giảm C làm tăng cả hai tỷ lệ, đúng như xu hướng trong bài báo, nhưng việc tăng q lại làm giảm chúng, đồng thời tỷ lệ phát hiện phần lớn chỉ dao động trong khoảng 8–34% ngoại trừ tại các điểm cực trị $C = 0.010$ và $q = 5$ (bài báo: 82–99% với tỷ lệ báo động giả dưới 6%). Chúng tôi vẫn chưa thể xác định được nguyên nhân khiến cơ chế này hành xử khác biệt một khi nó được kích hoạt.




Fig. 14. Average Rand index, execution time, number of SVs and BSVs, and memory usages versus chunk size M .

(a) Bài báo gốc

(b) Lần chạy này

Figure 7: Hình 14, Chỉ số Rand trung bình, thời gian thực thi, số lượng SV và BSV, và dung lượng bộ nhớ theo kích thước khối M .

Phân tích. Tương tự bài báo, chỉ số Rand duy trì ổn định theo M , và bộ nhớ cùng bậc độ lớn (18–181 KB so với 12–230 KB) và cao hơn trên KDD CUP'99 so với các luồng 2 chiều; ở đây chúng tôi đo kích thước mô hình (model size) thay vì mức sử dụng bộ nhớ đỉnh (peak memory usage) như bài báo. Hai đồ thị có sự khác biệt: Thời gian chạy giảm dần khi M tăng, trái ngược với bài báo là thời gian tăng theo M . Một lý do hợp lý là mỗi bài toán QP bị chi phối chủ yếu bởi tập tóm tắt đã lưu (khoảng 500 SV trên Smileface-Two moons) thay vì bởi M điểm mới, khiến chi phí trên mỗi chunk xấp xỉ không đổi và tổng số lượng chunk quyết định tổng thời gian; giả thuyết này hiện chưa được đo đạc chi tiết (profile). Số lượng điểm tóm tắt vượt quá ngưỡng 200 của bài báo (503–516 SV trên Smileface-Two moons, khoảng 870 trên CoverType), bởi vì khi thiếu vắng BSV thì không có cơ chế nào dọn dẹp điểm nhiều (Hình 7–10).




Fig. 15. Average Rand index versus Gaussian kernel parameter q on the four testing streams.

(a) Bài báo gốc

(b) Lần chạy này

Figure 8: Hình 15, Chỉ số Rand trung bình theo độ rộng hàm nhân q trên lưới tham số của bài báo.

Phân tích. Các đồ thị dữ liệu tổng hợp duy trì rất sát với bài báo, một phần nhờ vào bước hiệu chuẩn: Ring-Ball dao động trong khoảng 0.85–0.92 (bài báo 0.85–0.93) nhưng đạt đỉnh tại $q = 11$ thay vì 9, còn Smileface-Two moons đi ngang ở mức 0.983–0.986 với đỉnh tại $q = 12$ (bài báo là 11). Các điểm tối ưu không trùng khớp chính xác tuyệt đối với giá trị trong bài báo vì lược quét hiệu chuẩn trên luồng chưa có giãn sử dụng lưới số nguyên, nên $q^* = 8$ và $q^* = 50$ chỉ mang tính xấp xỉ, đồng thời lưới đã có giãn khảo sát những độ rộng mà bước hiệu chuẩn chưa từng thử nghiệm. Các đồ thị dữ liệu thực không thể so sánh tương đương. Trên KDD CUP'99, chỉ số đạt 0.97–1.00 và giảm từ từ theo q (bài báo ≈ 0.66), điều này phản ánh việc lấy mẫu tiền tố 10.000 bản ghi bị chi phối bởi quá ít lớp phân loại hơn là do chất lượng phân cụm thực sự tốt. Trên CoverType, chỉ số đi ngang ở mức 0.33 với tỷ lệ phát hiện cụm bằng 0 và tập tóm tắt lên tới khoảng 870 SV (Hình 14), hoàn toàn nhất quán với một hàm nhân vẫn còn quá hẹp ngay cả sau khi chuẩn hóa

min-max (Mục 3.2). Một kiểm tra sơ bộ ngoài pipeline hình ảnh, chạy trên 30.000 bản ghi đầu tiên với chuẩn hóa min-max tính trên toàn bộ luồng, cho ra kết quả 0.52; do đó cả chiều dài luồng dữ liệu lẫn tập bản ghi dùng để tính tham số chuẩn hóa đều có thể tác động lớn; chỉ có việc chạy thực nghiệm trên toàn bộ luồng mới có thể đưa ra kết luận dứt điểm.




Fig. 16. Average Rand index versus tradeoff parameter C on the four testing streams.

(a) Bài báo gốc

(b) Lần chạy này

Figure 9: Hình 16, Chỉ số Rand trung bình theo tham số đánh đổi C trên lưới tham số của bài báo.

Phân tích. Không có điểm tối ưu nào như trong bài báo xuất hiện (Ring-Ball tại $C = 0.25$, Smileface-Twomoons tại 0.3, CoverType tại 0.2). Trong khoảng $C \in [0.1, 0.32]$, ràng buộc hợp trong Công thức (5) thực tế hầu như không bao giờ bão hòa (Hình 4), nên C không tạo ra ảnh hưởng mang tính hệ thống: Smileface-Twomoons giữ nguyên ở mức 0.980–0.986, KDD CUP’99 ở 0.986–0.987 và CoverType ở 0.328, trong khi Ring-Ball biến thiên hỗn loạn giữa 0.89 và 0.93 mà không có xu hướng cụ thể.




Fig. 17. Average Rand index versus multisphere parameters, i.e., δ and η .

(a) Bài báo gốc

(b) Lần chạy này

Figure 10: Hình 17, Chỉ số Rand trung bình theo các ngưỡng đa cầu δ và η (lần chạy này: chỉ thực hiện trên hai luồng tổng hợp).

Phân tích. Giống như bài báo, cấu hình mặc định $(\delta, \eta) = (0.6, 1.0)$ nằm ngay tại hoặc sát bên cạnh ô tối ưu nhất: đây là cấu hình tốt nhất trên Ring-Ball (0.919) và cách ô tối ưu không quá 0.002 trên Smileface-Twomoons (0.984 so với 0.986 tại $\delta = 0.4$). Tuy nhiên, độ nhạy tham số của bài báo không tái hiện được. Mặt biểu diễn của bài báo sụt giảm xuống còn khoảng 0.4–0.7 khi cả δ và η cùng nhỏ, trong khi ở đây η hoàn toàn không có tác dụng (mọi hàng trong biểu đồ nhiệt đều đồng nhất) và δ chỉ làm thay đổi chỉ số Rand tối đa 0.03 (Ring-Ball giảm xuống 0.89 tại $\delta = 0.4$ –0.5). Một nguyên nhân khả dĩ là kiểm thử gộp cầu hiếm khi hoặc không bao giờ được chạm tới: η chỉ có ý nghĩa một khi tồn tại từ hai hình cầu trở lên, trong khi Hình 7–10 cho thấy chỉ có duy nhất một hình cầu tại mỗi bước. Số lượng hình cầu theo từng bước hiện chưa được ghi nhận (log). Khung benchmark chỉ chạy hai luồng tổng hợp nên đồ thị KDD CUP’99 và CoverType của bài báo không được tái hiện.





Figure 17: average Rand index versus the multisphere thresholds δ and η






Fig. 18. Comparing the performances of SVStream with five algorithms.

(a) Bài báo gốc

(b) Lần chạy này

Figure 11: Hình 18, Chỉ số Rand, thời gian thực thi và bộ nhớ so với các baseline trong River, với thiết lập giữ nguyên của Hình 18 (luồng tổng hợp chưa co giãn, tiền tố 10.000 bản ghi dữ liệu thực).

Phân tích. SVStream đạt điểm cao nhất trên Ring-Ball (0.918 so với tối đa 0.60 của các thuật toán khác) và trên KDD CUP'99 (0.982), tuy nhiên cả hai đều không phải là bằng chứng vững chắc: các baseline chạy với tham số River chưa tinh chỉnh (trong khi bài báo ghi nhận RepStream đạt 0.86 trên Ring-Ball), và đoạn tiền tố KDD bị chi phối bởi quá ít lớp. SVStream tụt lại phía sau trên Smileface-Twomoons (0.762, đứng sau CluStream, DenStream và STREAMKMeans) và đứng cuối trên CoverType (0.328). Kết quả trên Smileface-Twomoons là do hình này giữ luồng dữ liệu chưa co giãn; ở thang đo đã hiệu chuẩn, SVStream đạt tới 0.984 (Hình 11–12). SVStream chỉ có dung lượng bộ nhớ nhỏ nhất trên Ring-Ball; DenStream nhỏ hơn trên cả ba luồng còn lại. Phép so sánh này cũng khác với bài báo do các mô hình đối chuẩn (các bản cài đặt trong River, không có StrAP, tham số ε của DenStream được co giãn lại theo dữ liệu), việc triển khai bằng Python, và cách định nghĩa chỉ số bộ nhớ.

Takeaway. Chỉ có các tham số đầu vào là có thể tuân theo bài báo một cách tuyệt đối; các luồng dữ liệu tổng hợp chỉ có thể được tái tạo và co giãn lại thang đo, và các luồng dữ liệu thực ở đây là các mẫu lấy 10.000 bản ghi tiền tố. Khi thang đo tọa độ được hiệu chuẩn, Smileface-Twomoons và Ring-Ball tiệm cận rất sát chất lượng phân cụm của bài báo, tuy nhiên cơ chế BSV trong Công thức (5) không bao giờ kích hoạt tại giá trị C của bài báo, do đó việc phát hiện ngoại lai, nghiên cứu độ nhạy C và kích thước tập tóm tắt vẫn còn khác biệt đáng kể so với bài báo gốc.

4. Khó khăn & Vấn đề Tồn đọng

Quá trình tái hiện thực nghiệm SVStream (Mục 3) đã làm bộc lộ nhiều vấn đề mở. Mỗi vấn đề dưới đây đều cản trở việc khẳng định rằng bản cài đặt hoàn toàn trùng khớp với bài báo gốc.

- B1. Cơ chế BSV không kích hoạt tại mức C của bài báo.** Theo đúng nghĩa đen của Công thức (5), một hình cầu chỉ có thể chứa tối đa $\lfloor 1/C \rfloor$ BSV, nhưng bài báo lại hiển thị từ 10–14 BSV. Hậu quả là tỷ lệ phát hiện ngoại lai đạt 0% trên lưới tham số của bài báo, các đường cong biến thiên theo C đi ngang và tập tóm tắt vượt quá giới hạn 200 của bài báo. Tham số C trong bài báo có thể biểu thị tỷ lệ phần trăm BSV, tức là $C_{\text{eff}} = 1/(C \cdot M)$; cách diễn giải này hiện chưa được kiểm nghiệm thực tế.
- B2. Khâu phát hiện điểm ngoại lai hành xử khác biệt ngay cả trong vùng ràng buộc hộp phát huy tác dụng.** Với $C \leq 0.022$, tỷ lệ phát hiện duy trì ở mức 8–34% và tác động của q bị đảo ngược. Nguyên nhân cụ thể vẫn chưa được xác định.
- B3. Các ngưỡng đa cầu (multisphere) không phát huy tác dụng.** Trong Hình 17, η hoàn toàn không có hiệu lực và δ chỉ làm thay đổi chỉ số Rand tối đa 0.03. Nguyên nhân khả dĩ là hình cầu thứ hai hiếm khi hoặc không bao giờ được tạo ra, dẫn đến việc điều kiện gộp cầu không bao giờ được kích hoạt, tuy nhiên số lượng hình cầu tại mỗi bước hiện chưa được ghi nhận (log).
- B4. Hàm nhân trên CoverType vẫn còn quá hẹp.** Phương pháp chuẩn hóa min-max được lựa chọn mang lại $q \cdot \max \|\mathbf{x}_i - \mathbf{x}_j\|^2 = 27.6$ thay vì xấp xỉ 1, và chỉ số Rand bị giữ chặt ở mức 0.33 đối với mọi cấu hình tham số.

- B5. Các luồng dữ liệu thực chỉ mới là các mẫu tiền tố 10.000 bản ghi.** Việc chạy toàn bộ luồng tiêu tốn hàng chục giờ, đồng thời đoạn tiền tố của KDD CUP'99 bị chi phối bởi quá ít lớp, khiến chỉ số Rand 0.97–1.00 không mang nhiều thông tin đánh giá thực chất.
- B6. Xu hướng thời gian thực thi theo M chưa được lý giải rõ ràng.** Thời gian chạy giảm dần khi M tăng, trái ngược với bài báo; nguyên nhân phỏng đoán (tập tóm tắt đã lưu chiếm ưu thế áp đảo trong mỗi bài toán QP) vẫn chưa được đo đạc phân tích chi tiết (profile).
- B7. So sánh với các baseline đối chuẩn chưa thực sự công bằng.** Các baseline ở Hình 18 sử dụng cấu hình mặc định chưa qua tinh chỉnh của River (chỉ co giãn tham số ε của DenStream, không có StrAP), điều này mâu thuẫn với mục tiêu so sánh công bằng của phương pháp luận được nêu trong Mục 2.
- B8. Không thể tái hiện chính xác tuyệt đối các thực nghiệm tổng hợp nếu thiếu dữ liệu gốc từ tác giả.** Ring-Ball và Smileface-Twomoons không bao giờ được công bố công khai, do đó chúng tôi chỉ có thể tái tạo lại dựa trên ước lượng và hiệu chuẩn thang đo.

5. Kế hoạch Tuần Tiếp theo

Trong tuần tiếp theo, kế hoạch làm việc tập trung vào 3 nhiệm vụ trọng tâm:

- N1. Cài đặt thuật toán & bổ sung metrics mới:** Nghiên cứu kỹ chi tiết thuật toán để tối ưu mã nguồn, tránh sai sót tái lập và tích hợp thêm các chỉ số đánh giá khả năng thích ứng trôi dạt (concept drift).
- N2. Benchmark siêu tham số & pipeline LODO thử nghiệm:** Đào sâu bài toán siêu tham số, xây dựng và kiểm thử trước pipeline LODO với tham số tương đối trước khi áp dụng cho các thuật toán trọng yếu.
- N3. Tìm hiểu phân cụm luồng văn bản (textclust):** Khảo sát cơ chế của textclust và đánh giá khả năng tích hợp vào khuôn khổ benchmark nếu còn thời gian.

6. Tài liệu Tham khảo & Liên kết

Mã nguồn phát triển trong kỳ báo cáo này

Mã module	Mô tả chi tiết	Liên kết
Module 1	Thiết lập pipeline và Bộ chỉ số đánh giá (ARI, NMI, Silhouette, v.v.)	[TODO: link]
Module 2	Triển khai các thuật toán phân cụm luồng (nền tảng & khám phá)	[TODO: link]
Module 3	Khung kiểm thử siêu tham số (Relative LODO Benchmark)	[TODO: link]

Tài liệu tham khảo học thuật

References

- [1] V. Cerqueira, H. M. Gomes, M. Heyden, B. Pfahringer, and A. Bifet, “A Framework for Evaluating and Benchmarking Concept Drift Detection Methods,” in *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2 (KDD '26)*, Association for Computing Machinery, 2026. DOI: [10.1145/3770855.3819070](#).
- [2] L. Franceschi, M. Donini, V. Perrone, A. Klein, C. Archambeau, M. Seeger, M. Pontil, and P. Frasconi, “Hyperparameter Optimization in Machine Learning,” *arXiv preprint arXiv:2410.22854v3*, 2024. DOI: [10.48550/arXiv.2410.22854](#).
- [3] X. Fan, Y. Yue, P. Sarkar, and Y. X. R. Wang, “On Hyperparameter Tuning in General Clustering Problems,” in *Proceedings of the 37th International Conference on Machine Learning (ICML 2020)*, PMLR 119, pp. 2996–3007, 2020. URL: [proceedings.mlr.press/v119/fan20b.html](#).

- [4] T. Zhang, R. Ramakrishnan, and M. Livny, “BIRCH: An Efficient Data Clustering Method for Very Large Databases,” in *Proceedings of the 1996 ACM SIGMOD International Conference on Management of Data*, pp. 103–114, Association for Computing Machinery, 1996. DOI: [10.1145/233269.233324](https://doi.org/10.1145/233269.233324).
- [5] N. Ismael, M. Alzaalan, and W. Ashour, “Improved Multi Threshold Birch Clustering Algorithm,” *International Journal of Artificial Intelligence and Applications for Smart Devices*, vol. 2, no. 1, pp. 1–10, 2014. DOI: [10.14257/ijaiasd.2014.2.1.01](https://doi.org/10.14257/ijaiasd.2014.2.1.01).
- [6] S. Lühr and M. Lazarescu, “Incremental Clustering of Dynamic Data Streams Using Connectivity Based Representative Points,” *Data & Knowledge Engineering*, vol. 68, no. 1, pp. 1–27, 2009. DOI: [10.1016/j.datak.2008.08.006](https://doi.org/10.1016/j.datak.2008.08.006).
- [7] C. Isaksson, M. H. Dunham, and M. Hahsler, “SOSstream: Self Organizing Density-Based Clustering over Data Stream,” in *Machine Learning and Data Mining in Pattern Recognition*, Lecture Notes in Computer Science, vol. 7376, pp. 264–278, Springer, 2012. DOI: [10.1007/978-3-642-31537-4_21](https://doi.org/10.1007/978-3-642-31537-4_21).
- [8] C.-D. Wang, J.-H. Lai, D. Huang, and W.-S. Zheng, “SVStream: A Support Vector-Based Algorithm for Clustering Data Streams,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 25, no. 6, pp. 1410–1424, 2013. DOI: [10.1109/TKDE.2011.263](https://doi.org/10.1109/TKDE.2011.263).
- [9] A. Ben-Hur, D. Horn, H. T. Siegelmann, and V. Vapnik, “Support Vector Clustering,” *Journal of Machine Learning Research*, vol. 2, pp. 125–137, 2001.